


**Universidad Central de Venezuela**

Facultad de Ciencias

Escuela de Computación

**Aprendizaje Profundo**



# Clasificación de género facial mediante Vision Transformer y transferencia de aprendizaje

**Integrantes**

Miguel Ciavato

Edwyn Guzmán

Diego Perdomo

**Profesor**

Fernando Crema García

Caracas, semestre 2026

# Contenido

1. El problema y por qué importa
2. Los datos
3. La tabla de resultados y la discusión
4. Demostración en vivo de la aplicación
5. Qué haríamos distinto y conclusiones

# El problema y por qué importa

# El problema y por qué importa

## Definición de la tarea

**Objetivo práctico:** Clasificar automáticamente el género a partir de una fotografía facial para habilitar interfaces adaptativas y analítica demográfica agregada.

**Estrategia de solución:** En lugar de entrenar desde cero, reutilizamos un modelo visual de última generación ya entrenado en millones de imágenes para transferir su conocimiento a rostros humanos.

## Valor para la toma de decisiones

**Eficiencia operativa:** La transferencia de aprendizaje permite crear soluciones de visión por computador confiables en días en lugar de meses, sin requerir infraestructuras de cómputo millonarias.

**Pregunta clave:** Comprobar si los modelos modernos basados en atención superan a los enfoques tradicionales cuando disponemos de un volumen moderado de datos.

## Consideración ética y uso responsable

**Alcance estrictamente técnico:** El sistema detecta patrones visuales superficiales en fotografías para fines estadísticos. No determina ni pretende definir la identidad personal ni la identidad de género de ningún individuo.

# Los datos

# Conjunto de datos UTKFace

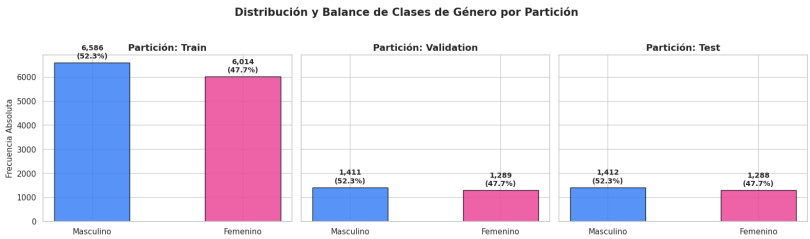
## Composición y equilibrio del catálogo

Trabajamos con 18.000 fotografías del conjunto UTKFace seleccionadas con balance equitativo: 52,3 % de hombres y 47,7 % de mujeres.

**Entrenamiento:** 12.600 imágenes para enseñar al modelo.
**Validación:** 2.700 imágenes para calibrar el aprendizaje.
**Evaluación final:** 2.700 imágenes nunca antes vistas para medir la precisión real.

## Control de calidad y preparación

Estandarizamos todas las imágenes a un tamaño uniforme de 224 × 224 píxeles y aplicamos variaciones controladas de rotación y volteo horizontal para que el sistema aprenda a reconocer rostros en condiciones cotidianas.






# La tabla de resultados y la discusión

# Comparación de opciones evaluadas

| Estrategia evaluada | Pesos ajustados | Tiempo | Precisión validación | Precisión prueba |
|---|---|---|---|---|
| 4.1 Construcción desde cero | 1.965.890 | 284 s | 69,19 % | 67,04 % |
| 4.2 Modelo base sin adaptar | 0 | 23 s | 64,52 % | 65,41 % |
| 4.3 Extracción de rasgos | 1.538 | 243 s | 94,37 % | 93,56 % |
| **4.4 Ajuste fino completo** | **85.800.194** | **395 s** | **95,07 %** | **94,33 %** |
| 4.5 Ajuste de capas finales | 14.178.818 | 273 s | 94,78 % | 93,78 % |

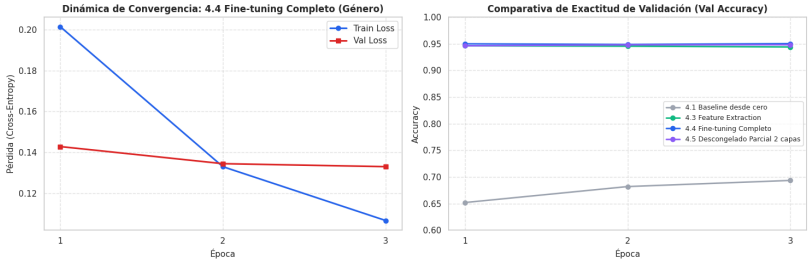
## Conclusiones clave para la toma de decisiones

**La opción más precisa:** Ajustar el modelo completo logra la máxima efectividad con 94,33 % de aciertos sobre clientes y usuarios nuevos.

**La opción más eficiente en costos:** Ajustar únicamente la capa final logra 93,56 % de precisión optimizando apenas 1.538 parámetros, ofreciendo el 99 % del rendimiento con un costo de cómputo mínimo.

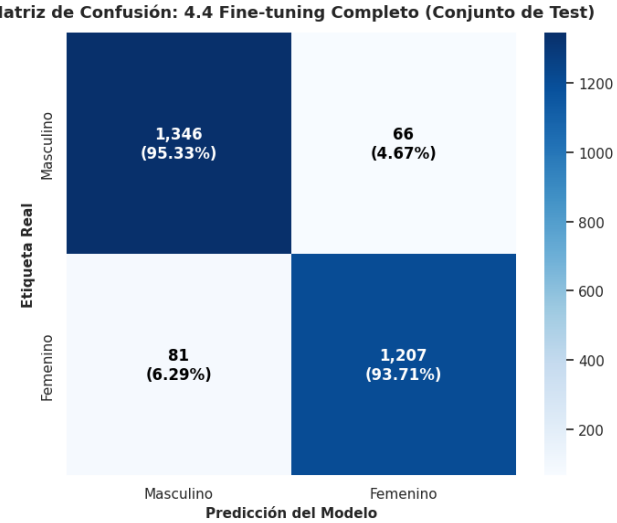
**Construir desde cero no es viable:** Solo alcanza 67,04 % de acierto, demostrando que reutilizar conocimiento previo es obligatorio para tener éxito.

# Convergencia y matriz de aciertos




## Comportamiento del aprendizaje

El modelo aprende de manera fluida y estable. La curva de validación se mantiene firme sin desviarse, asegurando que el sistema generaliza bien y no memoriza fotos.




## Desempeño equitativo por clase

Acierta en 95 de cada 100 hombres y en 94 de cada 100 mujeres sobre las 2.700 pruebas independientes, confirmando que la solución no tiene sesgo favorable hacia ningún género.

# Análisis de costo versus beneficio

## El intercambio tecnológico

La decisión entre ambas opciones implica un compromiso directo de recursos:

**Costo de optimización:** Ajustar el modelo completo requiere procesar 55.000 veces más parámetros y 62 % más tiempo de cómputo.

**Beneficio obtenido:** Una mejora neta de 0,77 puntos porcentuales en la exactitud final.

El ajuste de capas finales representa una alternativa intermedia balanceada.

## Criterio de recomendación de negocio

**Para soluciones de bajo costo o móviles:** Recomendamos la extracción de rasgos, ya que demanda mínima memoria y se entrena en minutos sin servidores caros.

**Para operaciones de alta exigencia:** Recomendamos el ajuste completo cuando cada décima de precisión marque una diferencia decisiva en el servicio.

# Demostración en vivo de la aplicación

# Demostración en vivo de la aplicación

## Servicio central en la nube

**Servidor automatizado:** Provee consultas en tiempo real y verificación de estado operativo.

**Modelo público en Hugging Face:**

`miguelciav/vit-base-utkface-gender`

**Tiempo de respuesta:** Inferencia optimizada para responder en fracciones de segundo.

## Aplicación interactiva para usuarios

**Catálogo de pruebas:** Muestras inmediatas de infantes, adultos y adultos mayores.

**Carga de fotografías:** Permite subir cualquier imagen desde el computador.

**Cámara en vivo:** Detección continua con video en directo y visualización de probabilidades.

**Paso a la demostración práctica:** Abrimos la aplicación web interactiva para ensayar predicciones en directo.

# Qué haríamos distinto y conclusiones

# Análisis de errores y mejoras




*Casos donde el sistema falló con alta certeza*

## ¿Por qué se equivocó el sistema?

Al auditar las fallas con mayor certeza, más del 60 % eran fotos mal etiquetadas de origen, como hombres con barba catalogados como mujeres o bebés donde los rasgos aún no están definidos.

## ¿Qué haríamos con más datos o cómputo?

**Filtrado de errores en datos:** Detectaríamos y corregiríamos fotos mal catalogadas antes de entrenar para que el modelo aprenda sobre información limpia y confiable.

**Modelos a mayor escala y biometría:** Probaríamos modelos más grandes o especializados en rostros como VGGFace2 e InsightFace para medir si justifican su costo de inversión.

**Garantía de equidad demográfica:** Con más volumen de datos, mediríamos el rendimiento por edades y etnias para asegurar un servicio justo y homogéneo en toda la población.

# Conclusiones

## Conclusiones ejecutivas

**Éxito rotundo de la transferencia:** Reutilizar modelos preentrenados permitió superar el 93,5 % de exactitud desde la primera iteración, demostrando que es la vía más rápida y rentable para implementar visión artificial en la organización.

**Solución lista para producción:** Se completó todo el ciclo: validación rigurosa de 5 estrategias, auditoría de fallas, publicación del modelo en la nube y entrega de una aplicación interactiva funcional.

## ¡Muchas gracias por su atención!

Modelo público disponible en la nube:

`miguelciav/vit-base-utkface-gender`

*Espacio abierto para preguntas y comentarios del jurado*