Universidad Central de Venezuela

Facultad de Ciencias

Escuela de Computación

Aprendizaje Profundo

Clasificación de género facial mediante Vision Transformer y transferencia de aprendizaje

Integrantes

Miguel Ciavato

Edwyn Guzmán

Diego Perdomo

Profesor

Fernando Crema García

Caracas, semestre 2026

Contenido

1. El problema y por qué importa
2. Los datos
3. La tabla de resultados y la discusión
4. Demostración en vivo de la aplicación
5. Qué haríamos distinto y conclusiones

El problema y por qué importa

El problema y por qué importa

Definición de la tarea

Objetivo práctico: Clasificar automáticamente el género a partir de una fotografía facial para habilitar interfaces adaptativas y analítica demográfica agregada.

Estrategia de solución: En lugar de entrenar desde cero, reutilizamos un modelo visual de última generación ya entrenado en millones de imágenes para transferir su conocimiento a rostros humanos.

Valor para la toma de decisiones

Eficiencia operativa: La transferencia de aprendizaje permite crear soluciones de visión por computador confiables en días en lugar de meses, sin requerir infraestructuras de cómputo millonarias.

Pregunta clave: Comprobar si los modelos modernos basados en atención superan a los enfoques tradicionales cuando disponemos de un volumen moderado de datos.

Consideración ética y uso responsable

Alcance estrictamente técnico: El sistema detecta patrones visuales superficiales en fotografías para fines estadísticos. No determina ni pretende definir la identidad personal ni la identidad de género de ningún individuo.

Los datos

Conjunto de datos UTKFace

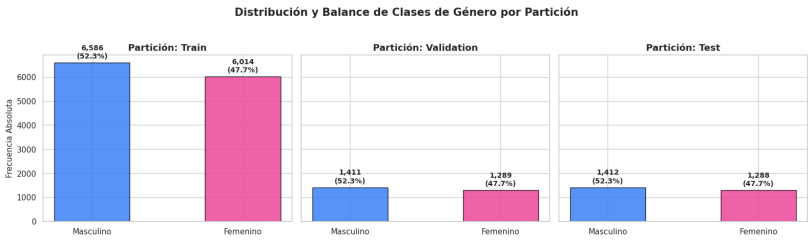
Composición y equilibrio del catálogo

Trabajamos con 18.000 fotografías del conjunto UTKFace seleccionadas con balance equitativo: 52,3 % de hombres y 47,7 % de mujeres.

Entrenamiento: 12.600 imágenes para enseñar al modelo.
Validación: 2.700 imágenes para calibrar el aprendizaje.
Evaluación final: 2.700 imágenes nunca antes vistas para medir la precisión real.

Control de calidad y preparación

Estandarizamos todas las imágenes a un tamaño uniforme de 224 $\times$ 224 píxeles y aplicamos variaciones controladas de rotación y volteo horizontal para que el sistema aprenda a reconocer rostros en condiciones cotidianas.





La tabla de resultados y la discusión

Comparación de opciones evaluadas

Estrategia evaluada	Pesos ajustados	Tiempo	Precisión validación	Precisión prueba
4.1 Construcción desde cero	1.965.890	284 s	69,19 %	67,04 %
4.2 Modelo base sin adaptar	0	23 s	64,52 %	65,41 %
4.3 Extracción de rasgos	1.538	243 s	94,37 %	93,56 %
4.4 Ajuste fino completo	**85.800.194**	**395 s**	**95,07 %**	**94,33 %**
4.5 Ajuste de capas finales	14.178.818	273 s	94,78 %	93,78 %

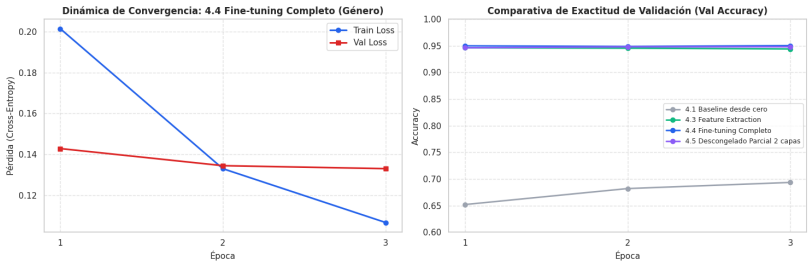
Conclusiones clave para la toma de decisiones

La opción más precisa: Ajustar el modelo completo logra la máxima efectividad con 94,33 % de aciertos sobre clientes y usuarios nuevos.

La opción más eficiente en costos: Ajustar únicamente la capa final logra 93,56 % de precisión optimizando apenas 1.538 parámetros, ofreciendo el 99 % del rendimiento con un costo de cómputo mínimo.

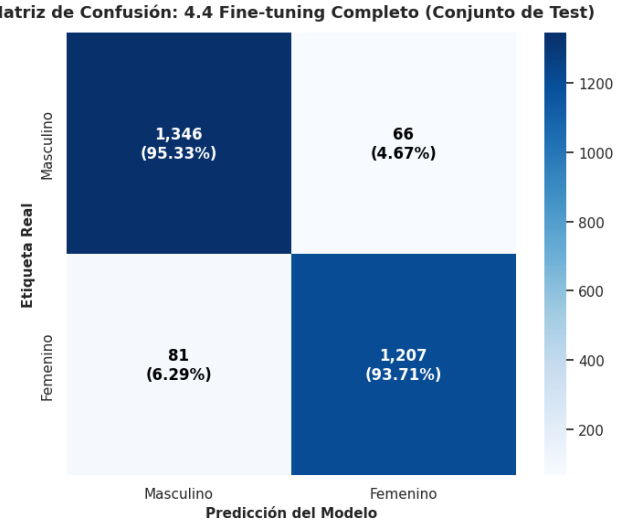
Construir desde cero no es viable: Solo alcanza 67,04 % de acierto, demostrando que reutilizar conocimiento previo es obligatorio para tener éxito.

Convergencia y matriz de aciertos



Comportamiento del aprendizaje

El modelo aprende de manera fluida y estable. La curva de validación se mantiene firme sin desviarse, asegurando que el sistema generaliza bien y no memoriza fotos.



Desempeño equitativo por clase

Acierta en 95 de cada 100 hombres y en 94 de cada 100 mujeres sobre las 2.700 pruebas independientes, confirmando que la solución no tiene sesgo favorable hacia ningún género.

Análisis de costo versus beneficio

El intercambio tecnológico

La decisión entre ambas opciones implica un compromiso directo de recursos:

Costo de optimización: Ajustar el modelo completo requiere procesar 55.000 veces más parámetros y 62 % más tiempo de cómputo.

Beneficio obtenido: Una mejora neta de 0,77 puntos porcentuales en la exactitud final.

El ajuste de capas finales representa una alternativa intermedia balanceada.

Criterio de recomendación de negocio

Para soluciones de bajo costo o móviles: Recomendamos la extracción de rasgos, ya que demanda mínima memoria y se entrena en minutos sin servidores caros.

Para operaciones de alta exigencia: Recomendamos el ajuste completo cuando cada décima de precisión marque una diferencia decisiva en el servicio.

Demostración en vivo de la aplicación

Demostración en vivo de la aplicación

Servicio central en la nube

Servidor automatizado: Provee consultas en tiempo real y verificación de estado operativo.

Modelo público en Hugging Face:

`miguelciav/vit-base-utkface-gender`

Tiempo de respuesta: Inferencia optimizada para responder en fracciones de segundo.

Aplicación interactiva para usuarios

Catálogo de pruebas: Muestras inmediatas de infantes, adultos y adultos mayores.

Carga de fotografías: Permite subir cualquier imagen desde el computador.

Cámara en vivo: Detección continua con video en directo y visualización de probabilidades.

Paso a la demostración práctica: Abrimos la aplicación web interactiva para ensayar predicciones en directo.

Qué haríamos distinto y conclusiones

Análisis de errores y mejoras



Casos donde el sistema falló con alta certeza

¿Por qué se equivocó el sistema?

Al auditar las fallas con mayor certeza, más del 60 % eran fotos mal etiquetadas de origen, como hombres con barba catalogados como mujeres o bebés donde los rasgos aún no están definidos.

¿Qué haríamos con más datos o cómputo?

Filtrado de errores en datos: Detectaríamos y corregiríamos fotos mal catalogadas antes de entrenar para que el modelo aprenda sobre información limpia y confiable.

Modelos a mayor escala y biometría: Probaríamos modelos más grandes o especializados en rostros como VGGFace2 e InsightFace para medir si justifican su costo de inversión.

Garantía de equidad demográfica: Con más volumen de datos, mediríamos el rendimiento por edades y etnias para asegurar un servicio justo y homogéneo en toda la población.

Conclusiones

Conclusiones ejecutivas

Éxito rotundo de la transferencia: Reutilizar modelos preentrenados permitió superar el 93,5 % de exactitud desde la primera iteración, demostrando que es la vía más rápida y rentable para implementar visión artificial en la organización.

Solución lista para producción: Se completó todo el ciclo: validación rigurosa de 5 estrategias, auditoría de fallas, publicación del modelo en la nube y entrega de una aplicación interactiva funcional.

¡Muchas gracias por su atención!

Modelo público disponible en la nube:

`miguelciav/vit-base-utkface-gender`

Espacio abierto para preguntas y comentarios del jurado